

1.SGLang 的 RadixAttention / RadixCache 解决的问题是降低重复的前缀，直接用他们的KVcache，不用再到prefill中在计算，降低FFTF

2.reuse是只计算未命中的后缀，不计算重复的前缀，新产生的再加入共享cache。
pagesized是为请求分配 KV 存储；维护逻辑 token 位置到物理 page 的映射；prefill 时写入大量 KV；decode 时逐 token 追加 KV；

3.vllm是解决KV碎片和固定分配的问题，假设固定分配4096，每次只会用到几十，几百，这就造成大量GPU空间被浪费，利用率极低，vllm就是切成更小块，比如16，提高利用率，同时用block管理物理和逻辑KV上的对应关系，被切分后物理上不会连续。
Radixattention可以减少重复部分的prefill，，通过前缀树，跳过命中部分，我感觉就是减少计算，类似于稀疏注意力（打个比方）。二者可以组和在一起。